

Vigilancia Epidemiológica de Dengue en México

Carlos Fernando Juárez Pacheco

Diplomado Manejo de Bases de Datos SQL y NoSQL en un Entorno de Nube
Módulo 6 — Conceptos Avanzados de Bases de Datos NoSQL

1 Problema y datos

1.1 Objetivo del proyecto

Apoyar la vigilancia epidemiológica de dengue en México mediante un modelo documental que permita identificar municipios con incidencia elevada, detectar posibles señales de propagación regional y caracterizar la evolución temporal de la enfermedad, a partir de datos abiertos oficiales.

1.2 Personas usuarias y decisión que apoya

Epidemiólogos estatales y brigadas de control que necesitan priorizar dónde y cuándo concentrar recursos de vigilancia y control.

1.3 Preguntas que responde el proyecto

1. ¿Qué municipios muestran mayor incidencia de casos confirmados en una semana epidemiológica dada?
2. ¿Cómo ha evolucionado la incidencia semanal de un municipio específico a lo largo del año?
3. ¿Qué municipios cercanos a un municipio con brote también muestran incidencia elevada, sugiriendo propagación regional?
4. ¿Existe estacionalidad reconocible en los casos a nivel nacional?
5. ¿Qué nivel de acceso a los datos debe tener cada rol, dado que son datos de salud sensibles?

1.4 Procedencia de los datos

Dirección General de Epidemiología (DGE/SINAVE), datos abiertos por caso individual, cruzados con el catálogo oficial de claves de municipio y entidad de la propia DGE, y con centroides y población municipal (fuente INEGI 2020). 42,219 casos individuales se agregaron en 10,353 documentos municipio-semana.

1.5 Modelo documental resumido

Colección única `casos_semanales`: un documento por combinación municipio + semana epidemiológica, con geometría Geo.JSON embebida y población embebida. Se decidió usar Extended Reference para evitar joins constantes en cálculos de incidencia.

2 Implementación

2.1 Modelo documental y validación

La colección `casos_semanales` usa un validador `$jsonSchema` con 9 campos obligatorios (`clave_municipio`, `municipio`, `entidad_federativa`, `semana_epidemiologica`, `fecha_inicio_semana`, `casos_confirmados`, `casos_probables`, `poblacion`, `geometry`) y 2 opcionales (`defunciones`, `fuentes`). Se probó con 6 documentos de control (2 válidos, 4 inválidos, cada uno aislando una sola inconsistencia: conteo negativo, campo obligatorio faltante, tipo de geometría incorrecto, coordenadas fuera de rango).

Nota: `$jsonSchema` no valida rangos numéricos por posición dentro de un arreglo, por lo que una coordenada como `longitud: 200` (fuera del rango válido $[-180, 180]$) es aceptada por el validador aunque sea geográficamente inválida. Esta validación se aplicó en la capa de ETL (Python), no en el servidor.

```
projecto_modulo db.casos_semanales.insertOne(valido1)
acknowledged: true,
insertedId: ObjectId('60b4395a77523971c9f8a1')
projecto_modulo db.casos_semanales.find().pretty()
{
  "_id": ObjectId('60b4395a77523971c9f8a1'),
  "clave_municipio": "14030",
  "municipio": "Guadalupe",
  "entidad_federativa": "1403",
  "semana_epidemiologica": { "anio": 2020, "semana": 33 },
  "fecha_inicio_semana": "2020-08-17T00:00:00-06:00",
  "casos_confirmados": 107,
  "casos_probables": 79,
  "defunciones": 1,
  "poblacion": 144180,
  "geometry": {
    "type": "Point",
    "coordinates": [ -85.3496, 28.4897 ] },
  "fuentes": "DGE/SINAVE",
  "fecha_carga": "2020-08-20T07:23:59.812Z"
}
projecto_modulo db.casos_semanales.insertOne(valido2)
acknowledged: true,
insertedId: ObjectId('60b4395a77523971c9f8a2')
projecto_modulo valido1
{
  "_id": ObjectId('60b4395a77523971c9f8a1'),
  "clave_municipio": "14030",
  "municipio": "Guadalupe",
  "entidad_federativa": "1403",
  "semana_epidemiologica": { "anio": 2020, "semana": 33 },
  "fecha_inicio_semana": "2020-08-17T00:00:00-06:00",
  "casos_confirmados": 107,
  "casos_probables": 79,
  "defunciones": 1,
  "poblacion": 144180,
  "geometry": {
    "type": "Point",
    "coordinates": [ -85.3496, 28.4897 ] },
  "fuentes": "DGE/SINAVE",
  "fecha_carga": "2020-08-20T07:23:59.812Z"
}
```

Documento 1 y 2 válidos.

```
Uncaught:
MongoServerError: Document failed validation
MongoServerError: {
  failingDocumentId: ObjectId('60b4395a77523971c9f8a3'),
  details: {
    errorName: 'JsonSchema',
    title: 'casos_semanales validation',
    schemaValidationFailed: {
      errors: {
        'entidad_federativa': {
          argumentNotSatisfied: {
            propertyName: 'geometry',
            details: {
              errorName: 'JsonSchema',
              propertyNotSatisfied: {
                propertyName: 'type',
                description: 'Must be 'Point'. Obligatoria.',
                details: {
                  errorName: 'enum',
                  values: [ 'Point' ],
                  reason: 'Must be one of enum',
                  consideredValue: 'Polygon'
                }
              }
            }
          }
        }
      }
    }
  }
}
projecto_modulo db.casos_semanales.insertOne(invalido3)
acknowledged: true,
insertedId: ObjectId('60b4395a77523971c9f8a3')
```

Documento 3 inválido y documento 4 válido (fuera de rango)

Figure 1: Pruebas realizadas sobre el validador de la colección `casos_semanales`.

2.2 Consultas principales e índices

Se identificaron tres patrones de consulta frecuentes y se diseñaron índices compuestos siguiendo la regla ESR (Equality-Sort-Range):

Consulta	Índice	Patrón
Top municipios por semana	idx_semana_casos	{anio:1, semana:1, casos_confirmados:-1}
Serie temporal de un municipio	idx_municipio_fecha_anio	{clave_municipio:1, fecha_inicio_semana:1, anio:1}
Casos por entidad en rango de fechas	idx_entidad_fecha	{entidad_federativa:1, fecha_inicio_semana:1}

Table 1: Índices compuestos diseñados según la regla ESR.

Medición antes/después (10,353 documentos reales, mismos parámetros y mismo `nReturned` en ambos casos):

Consulta	Plan antes	Plan después	keys	docs	nReturned
Top semana 25	COLLSCAN→SORT	IXSCAN	419	419	419
Serie Chiapas (07009)	COLLSCAN→SORT	IXSCAN	33	32	32
Chiapas ene-jul	COLLSCAN→SORT	IXSCAN	527	527	527

Table 2: Comparación de planes de ejecución antes y después de indexar.

En los tres casos desapareció la etapa `SORT` en memoria y el índice resolvió filtro y orden simultáneamente. Se añadieron dos índices adicionales: `idx_fecha_inicio_semana` (rango temporal sin filtro de zona, sección 3.2) e `idx_geometry_2dsphere` (consultas espaciales, sección 3.1).

3 Análisis especializado

3.1 Componente geoespacial

Se evaluó la pertinencia del análisis geoespacial revisando cada pregunta del proyecto contra una relación espacial explícita:

Pregunta	Entidad y geometría	Relación	Decisión
¿Qué municipios cercanos a un municipio con brote también muestran incidencia elevada?	Municipio (centroide, Point)	Proximidad	Integrar
¿Cuántos casos hay dentro de un radio de un punto de referencia?	Municipio (centroide, Point)	Proximidad (radio)	Integrar
¿Los casos coinciden con una región poligonal (ej. franja costera)?	Requeriría polígonos de región	Pertenencia (<code>\$geoWithin</code>)	Posponer

Table 3: Tabla de decisión de pertinencia geoespacial.

Se creó un índice `2dsphere` sobre `geometry` y se construyó un *pipeline* con `$geoNear` (primera etapa, como exige MongoDB) seguido de un filtro temático por semana y umbral de casos.

Caso de prueba real: el hotspot de la semana 25 de 2026 fue Hermosillo, Sonora (16 casos confirmados). Al buscar municipios dentro de 150 km con ≥ 3 casos confirmados esa misma semana, **solo Hermosillo cumplió el umbral**. Ningún municipio vecino mostró señal de propagación regional en esa semana específica. Como control, se verificó que Tapachula, Chiapas ($\sim 2,000$ km de distancia) no apareciera en el resultado, confirmando que `$maxDistance` acotó correctamente la búsqueda.

Limitación documentada: la comparación usó conteos absolutos, no tasas de incidencia. Hermosillo (936,263 hab.) y San Javier (537 hab.) no son comparables con el mismo umbral de “casos confirmados”. Un municipio pequeño con 1-2 casos puede tener una incidencia por 100,000 habitantes mayor que Hermosillo con 16.

Técnicas descartadas: \$geoWithin/\$geoIntersects sobre regiones reales se descartaron por falta de polígonos en el dataset actual. No se forzó su uso solo por completitud técnica.

```
db.casos_semanales.findOne({
  municipio: "TAPACHULA",
  "semana_epidemiologica.anio": 2026,
  "semana_epidemiologica.semana": 25
})
{
  _id: ObjectId('6a8d6d83b0f43f233d22811'),
  clave_municipio: "99889",
  semana_epidemiologica: { anio: 2026, semana: 25 },
  fecha_inicio_semana: ISODate('2026-06-21T00:00:00.000Z'),
  casos_confirmados: 2,
  casos_probables: 1,
  defunciones: 0,
  fuente: 'DGE/SINAVE - datos_abiertos_dengue',
  municipio: 'TAPACHULA',
  entidad_federativa: 'CHIAPAS',
  geometry: { type: 'Point', coordinates: [ -92.1551552, 14.5439857 ] },
  poblacion: 353766
}
```

Figure 2: Resultado del *pipeline* \$geoNear + filtro temático: municipios cercanos a Hermosillo (Sonora) con casos confirmados en la semana 25 de 2026.

3.2 Componente temporal

Se creó un índice simple sobre `fecha_inicio_semana` para consultas de rango sin filtro de zona, y un *pipeline* de agregación mensual como indicador interpretable:

Mes 2026	Casos confirmados	Municipios con casos
Enero	719	267
Febrero	352	183
Marzo	447	215
Abril	395	179
Mayo	682	286
Junio	614	263
Julio	730	334
Agosto*	213	107

Table 4: Serie mensual nacional de casos confirmados. *Agosto incompleto (datos hasta el 9 de agosto).

Interpretación: mayo-julio muestra la mayor actividad (682-730 casos/mes) frente al valle de febrero-abril (352-447), consistente con mayor transmisión en temporada de lluvias. Sin embargo, **enero rompe el patrón simple** (719 casos, casi al nivel del pico) - se documenta como posible efecto de cifras preliminares que la DGE ajusta en boletines posteriores, no se fuerza una narrativa estacional limpia que los datos no sostienen del todo.

Prueba con fechas conocidas: casos confirmados en enero (719) vs. junio-julio (1,344) - consistente con mayor transmisión en temporada de lluvias, aunque la excepción de enero matiza la conclusión.

Técnica descartada: búsqueda de texto libre (\$text) - el esquema es completamente agregado/estructurado, sin campos de texto libre. Se usó en su lugar una búsqueda por patrón (regex anclado) sobre nombres de municipio, para un caso de uso real (autocompletado en dashboard).

```
proyecto_modulo6> load("/tmp/temporal_semana4.js")
true
proyecto_modulo6> printjson(serieNacionalPorMes(db))
[
  {
    casos_confirmados: 719,
    casos_probables: 2520,
    defunciones: 43,
    municipios_con_casos: 267,
    mes: ISODate('2026-01-01T00:00:00.000Z')
  },
  {
    casos_confirmados: 352,
    casos_probables: 2305,
    defunciones: 33,
    municipios_con_casos: 183,
    mes: ISODate('2026-02-01T00:00:00.000Z')
  },
  ...
]
```

Figure 3: Salida del *pipeline* de agregación mensual (`serieNacionalPorMes`), mostrando la curva de casos confirmados/probables/defunciones por mes.

4 Seguridad y cierre

4.1 Clasificación de datos

Clasificación	Campos	Justificación
Público	clave_municipio, municipio, entidad_federativa, semana_epidemiologica, fecha_inicio_semana, poblacion	Datos censales/geográficos ya públicos de origen (INEGI, DGE)
Interno	fuelle, fecha_carga	Metadatos de trazabilidad, sin valor sensible pero no necesarios para consumo público
Sensible (condicional)	casos_confirmados, casos_probables, defunciones	Sensibilidad depende del tamaño de población del municipio, no solo del campo

Table 5: Clasificación de datos de la colección `casos_semanales`.

4.2 Minimización

1. **En el ETL:** el archivo crudo de la DGE incluye comorbilidades, embarazo, y otros datos de salud a nivel de persona. Ninguno de estos campos se transfiere al modelo agregado -se descartan por completo, no se enmascaran ni seudonimizan.

4.3 Matriz de roles (privilegio mínimo)

Rol	Colección/vista	Operación
brigada_campo	casos_semanales_publico	find
epidemiologo_estatal	casos_semanales (completa)	find
director_nacional	casos_semanales + vista	find
etl_loader	casos_semanales	insert, update, createIndex

Table 6: Matriz de roles con privilegio mínimo.

Se creó un usuario real (`test_brigada`) con el rol `brigada_campo` y se validó desde una sesión aparte:

- `db.casos_semanales_publico.findOne()` → **permitido**.
- `db.casos_semanales.findOne()` → **rechazado**: `MongoServerError[Unauthorized]: not authorized...`
- `db.casos_semanales.insertOne(...)` → **rechazado**: mismo tipo de error.

Esto distingue explícitamente un rol diseñado de una denegación comprobada.

```
(base) familia@MacBook-Air-4 ~ % docker exec -it c-fjp-diplo-mongodb mongosh -u test_brigada -p prueba123 --authenticationDatabase proyecto_modulo6
Current Mongosh Log ID: 6a8d6d2aa3c7220f49df8a2
Connecting to:
  mongodb://<credentials>@127.0.0.1:27017/?directConnection=true&serverSelectionTimeoutMS=2000&authSource=proyecto_modulo6&appName=mongosh+2.8.3
Using MongoDB:
  7.0.37
Using Mongosh:
  2.8.3

For mongosh info see: https://www.mongodb.com/docs/mongosh-shell/

test> use proyecto_modulo6
switched to db proyecto_modulo6
proyecto_modulo6> db.casos_semanales_publico.findOne()
{
  _id: ObjectId('6a8d6d2aa3c7220f49df8a2'),
  clave_municipio: '62001',
  semana_epidemiologica: { anio: 2026, semana: 1 },
  fecha_inicio_semana: ISODate('2026-01-04T00:00:00.000Z'),
  municipio: 'AGUASCALIENTES',
  entidad_federativa: 'AGUASCALIENTES',
  geometry: { type: 'Point', coordinates: [ -102.1745768, 21.5247362 ] },
  poblacion: 948998,
  casos_confirmados: 0,
  casos_probables: 0,
  defunciones: 0
}

proyecto_modulo6> db.casos_semanales.findOne()
MongoServerError[Unauthorized]: not authorized on proyecto_modulo6 to execute command { find: "casos_semanales", filter: {}, limit: 1, lsid: { id: UUID('7c781d67-8ac2-4aaf-a3fb-ab67cb6bb965') }, $db: "proyecto_modulo6" }

proyecto_modulo6> db.casos_semanales.insertOne({ prueba: 1 })
MongoServerError[Unauthorized]: not authorized on proyecto_modulo6 to execute command { insert: "casos_semanales", documents: [ { prueba: 1, _id: ObjectId('6a8d6d2aa3c7220f49df8a3') } ], ordered: true, lsid: { id: UUID('7c781d67-8ac2-4aaf-a3fb-ab67cb6bb965') }, $db: "proyecto_modulo6" }
```

Figure 4: Evidencia de la denegación real de acceso: el usuario `test_brigada` puede consultar la vista generalizada pero recibe `Unauthorized` al intentar leer o escribir la colección completa.

4.4 Resultados, límites y mejora

Resultados: el proyecto responde las 5 preguntas planteadas con evidencia reproducible - hotspot geoespacial identificado y verificado (Hermosillo), curva temporal mensual con interpretación matizada, y control de acceso comprobado con un usuario real.

Límites principales:

- Cobertura temporal de solo 32 semanas (un año parcial), sin comparación interanual.
- Geometría a nivel de centroide, no polígono - limita el análisis espacial a proximidad, no a pertenencia territorial.
- El `$jsonSchema` no cubre validación de rangos numéricos dentro de arreglos.
- Enero rompe el patrón estacional esperado, posiblemente por ajustes tardíos de cifras preliminares de la DGE.

Mejora posible: incorporar polígonos municipales completos (Marco Geoestadístico de INEGI) para habilitar `$geoWithin/$geoIntersects` sobre regiones reales, y ampliar la cobertura temporal a años previos para permitir comparación interanual real.